Aide-mémoire statistique

Formules, choix des tests, pièges · Version prototype

Formules essentielles

Notion	Formule
Moyenne	$\bar{x} = (1/n)\ \Sigma\ x_i$
Variance (échantillon)	$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$
Covariance	$\mathrm{cov}(X, Y) = E[XY] - E[X]E[Y]$
Corrélation	$\rho = \mathrm{cov}(X, Y) / (\sigma_X\ \sigma_Y)$, $\rho \in [-1, 1]$
Erreur-type de la moyenne	$\sigma/\sqrt{n}$ (estimée par $s/\sqrt{n}$)
Statistique t (une moyenne)	$t = (\bar{x} - \mu_0) / (s/\sqrt{n})$, ddl = $n - 1$
IC à 95 % (n grand)	$\bar{x} \pm 1{,}96 \cdot s/\sqrt{n}$
Binomiale	$P(X = k) = C(n, k)\ p^k\ (1 - p)^{n-k}$
Poisson	$P(X = k) = e^{-\lambda}\ \lambda^k / k!$
Bayes	$P(A\|B) = P(B\|A)\ P(A) / P(B)$
R^2	$1 - \mathrm{SCR}/\mathrm{SCT}$

Quel test choisir ?

Situation	Test	Fonction R
Moyenne d'un échantillon vs valeur	t de Student (1 éch.)	t.test(x, mu = m0)
Deux moyennes, groupes indépendants	t de Welch	t.test(x ~ g)
Deux mesures sur les mêmes individus	t apparié	t.test(x, y, paired = TRUE)
Proportion	Test sur proportion	prop.test(x, n)
Deux variables catégorielles	χ^2 d'indépendance	chisq.test(table)
Plus de deux moyennes	ANOVA à un facteur	aov(y ~ g)
Relation linéaire entre deux variables	Corrélation / régression	cor.test(x, y) ; lm(y ~ x)

Pièges classiques

- La p-valeur n'est **pas** $P(H_0$ vraie | données).
- « Non significatif » ne signifie pas « pas d'effet » : l'échantillon peut manquer de puissance.
- Corrélation ≠ causalité : une variable omise peut expliquer la relation.
- Un intervalle de confiance à 95 % ne contient pas le paramètre avec « 95 % de probabilité » une fois calculé ; c'est la *procédure* qui capture le vrai paramètre dans 95 % des échantillons répétés.

- Écart-type (dispersion des données) ≠ erreur-type (précision de l'estimation).
- Comparer plusieurs tests sans correction augmente le risque d'erreur de type I.

Commandes R utiles

```
summary(df) · str(df) · mean(x, na.rm = TRUE) · sd(x) · quantile(x)
hist(x) · boxplot(y ~ g) · plot(x, y) · abline(lm(y ~ x))
qnorm(0.975) · pnorm(1.96) · qt(0.975, df = n - 1)
```