Résumé de cours — Statistique 1

Notes de révision · Semestre d'automne · Version prototype

1. Statistique descriptive

Moyenne : $\bar{x} = (1/n)\ \Sigma\ x_i$. **Médiane** : valeur centrale de l'échantillon ordonné. La médiane est robuste aux valeurs extrêmes, contrairement à la moyenne.

Variance d'échantillon : $s^2 = (1/(n-1))\ \Sigma\ (x_i - \bar{x})^2$. Le diviseur $n-1$ (et non n) rend l'estimateur sans biais pour la variance de la population.

Écart-type : $s = \sqrt{s^2}$. Coefficient de variation : $CV = s / \bar{x}$ (pour $\bar{x} > 0$).

Quartiles et boîte à moustaches : IQR = Q3 − Q1 ; une observation est souvent qualifiée de atypique si elle sort de [Q1 − 1,5·IQR ; Q3 + 1,5·IQR].

2. Probabilités

- Axiomes de Kolmogorov : $P(A) \geq 0$; $P(\Omega) = 1$; additivité pour des événements disjoints.
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- Probabilité conditionnelle : $P(A \mid B) = P(A \cap B) / P(B)$, pour $P(B) > 0$.
- Indépendance : $P(A \cap B) = P(A) \cdot P(B)$.
- Formule de Bayes : $P(A \mid B) = P(B \mid A) \cdot P(A) / P(B)$.

Variables aléatoires

Espérance : $E[X] = \Sigma\ x\ P(X = x)$ (cas discret). Variance : $Var(X) = E[X^2] - (E[X])^2$. Linéarité : $E[aX + b] = a\ E[X] + b$; $Var(aX + b) = a^2\ Var(X)$.

3. Lois usuelles

Loi	Paramètres	Espérance	Variance
Bernoulli	p	p	$p(1-p)$
Binomiale $B(n, p)$	n, p	np	$np(1-p)$
Poisson	λ	λ	λ
Uniforme continue $[a, b]$	a, b	$(a+b)/2$	$(b-a)^2/12$
Normale $N(\mu, \sigma^2)$	μ, σ^2	μ	σ^2

Standardisation : si $X \sim N(\mu, \sigma^2)$, alors $Z = (X - \mu)/\sigma \sim N(0, 1)$. Valeurs de référence : $P(|Z| \leq 1{,}96) \approx 0{,}95$; $P(|Z| \leq 1{,}645) \approx 0{,}90$; $P(|Z| \leq 2{,}576) \approx 0{,}99$.

4. Théorème central limite et estimation

TCL : pour $X_1, \ldots, X_n$ indépendantes, de même loi, d'espérance μ et de variance σ^2 finie, $(\bar{X} - \mu)/(\sigma/\sqrt{n})$ converge en loi vers $N(0, 1)$ quand $n \to \infty$.

Intervalle de confiance pour une moyenne (σ inconnue, échantillon de taille n) : $\bar{x} \pm t_{n-1,\ 1-\alpha/2} \cdot s/\sqrt{n}$.

L'erreur-type de la moyenne est $\sigma/\sqrt{n}$: quadrupler l'échantillon divise l'incertitude par deux.

5. Tests d'hypothèses

On confronte H_0 (hypothèse nulle) à H_1. La **p-valeur** est la probabilité, sous H_0, d'obtenir une statistique de test au moins aussi extrême que celle observée. On rejette H_0 si $p < \alpha$. Ce n'est *pas* la probabilité que H_0 soit vraie.

	H_0 vraie	**H_0 fausse**
Rejet de H_0	Erreur de type I (prob. α)	Décision correcte (puissance $1 - \beta$)
Non-rejet de H_0	Décision correcte	Erreur de type II (prob. β)

6. Régression linéaire simple

Modèle : $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. Estimateurs des moindres carrés : $\beta_1 = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \Sigma(x_i - \bar{x})^2$; $\beta_0 = \bar{y} - \beta_1 \bar{x}$. Le coefficient de détermination R^2 mesure la part de variance de y expliquée par le modèle.

Dans R : `fit <- lm(y ~ x, data = df); summary(fit)`.